

Universidade Federal de Minas Gerais
Instituto de Ciências Exatas
Departamento de Ciência da Computação

Larissa Dolabella Gomide

ATIVIDADES PRÁTICAS E INTEGRADORAS

CLASSIFICAÇÃO AUTOMÁTICA DE MINERAIS

Belo Horizonte
2021 / 2º semestre

Universidade Federal de Minas Gerais
Instituto de Ciências Exatas
Departamento de Ciência da Computação
Curso de Bacharelado em Sistemas de Informação

CLASSIFICAÇÃO AUTOMÁTICA DE MINERAIS

por

Larissa Dolabella Gomide

Atividades Práticas e Integradoras

Apresentado como requisito da disciplina de Atividades Práticas e Integradoras do Curso de Bacharelado em Sistemas de Informação da UFMG

Prof. Wagner Meira Júnior
Orientador(a)

Prof. Rosaline Cristina Figueiredo e Silva
Orientador(a)

Belo Horizonte
2021 / 2º semestre

RESUMO

O presente trabalho foi desenvolvido com o objetivo de realizar a classificação de minerais utilizando ferramentas de aprendizado de máquina. Para isso uma base de dados com fotomicrografias de 16 espécies minerais diferentes foi organizada, e passada como entrada para um algoritmo de redes neurais convolucionais. Neste sentido foram desenvolvidos alguns modelos com variações no número de classes e hiperparâmetros, além de análises comparativas que são apresentadas no presente documento.

Palavras-chave: classificação de minerais, redes neurais convolucionais, crisp-dm

ABSTRACT

This monograph has been developed aiming to automate mineral classification using a machine learning toolkit to do so. To accomplish this a database with 16 mineral species has been organized and given as input to a convolutional neural network algorithm. In this context, some models were developed with variations in the number of classes and hyperparameters, in addition to comparative analyzes that are presented in this document.

Keywords: mineral classification, convolutional neural networks, crisp-dm

SUMÁRIO

1.	INTRODUÇÃO	6
2.	JUSTIFICATIVA	8
3.	OBJETIVOS.....	8
A.	OBJETIVO GERAL:	8
B.	OBJETIVOS ESPECÍFICOS:.....	8
4.	METODOLOGIA	9
5.	REVISÃO DA LITERATURA	10
6.	DATA UNDERSTANDING	11
7.	DATA PREPARATION	13
8.	MODELING.....	14
9.	EVALUATION	14
10.	RESULTADOS.....	14
11.	CONCLUSÃO	18
12.	REFERÊNCIAS BIBLIOGRÁFICAS	19

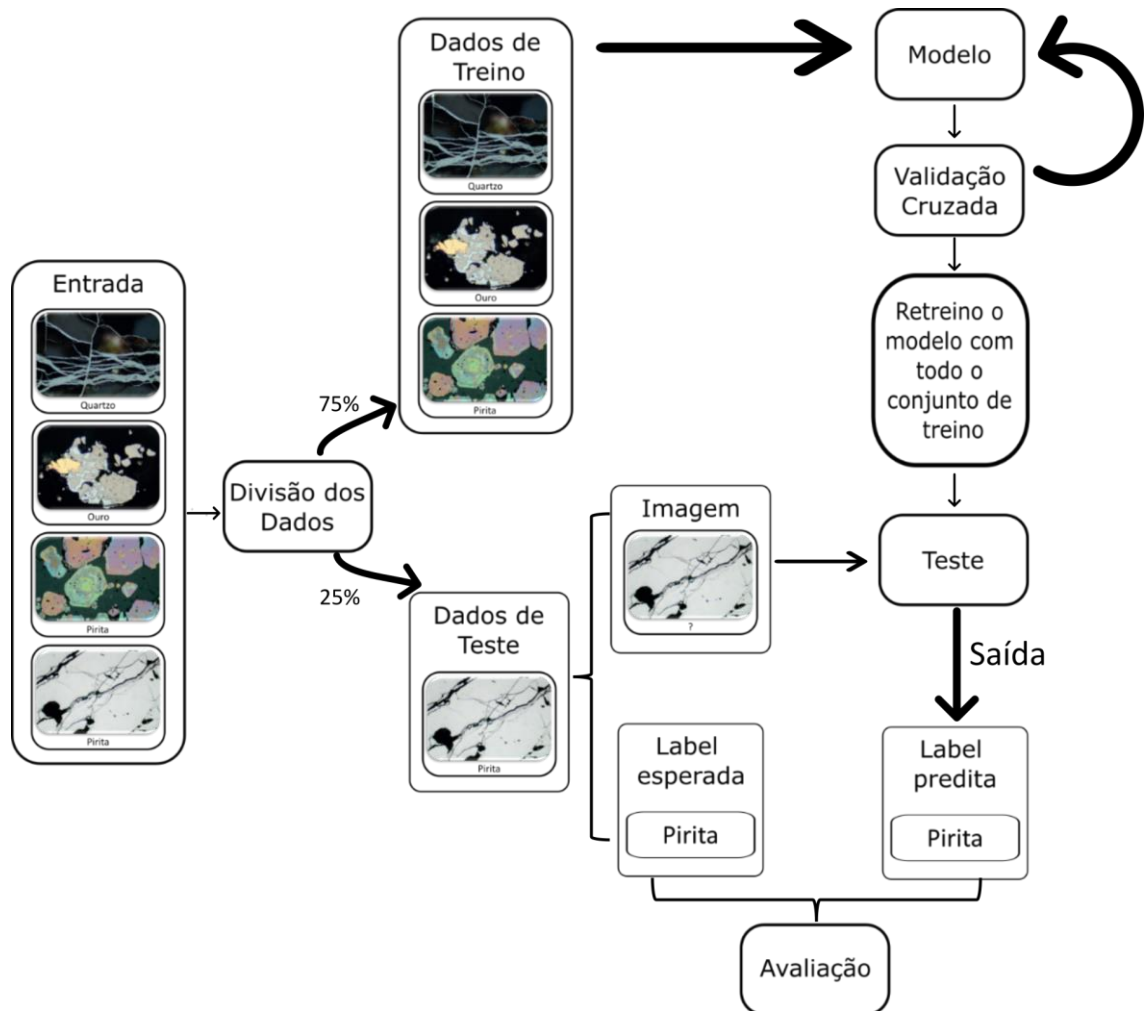
1. Introdução

Geologia, do grego: estudo da terra (SIGNIFICADOS.COM, 2016), é a ciência responsável por estudos acerca da composição da Terra, sua dinâmica e componentes abióticos (MARQUES, 2018) (SIGNIFICADOS.COM, 2016). Tais estudos por sua vez são divididos em campos como a geofísica, a paleontologia, petrografia, a mineralogia, entre outros. A mineralogia por sua vez, trata do estudo dos minerais que são estruturas cristalinas, sólidas, homogêneas, de composição química definida. Tais estudos, por sua vez, são relevantes, pois ajudam a compreender melhor as propriedades físico-químicas desses materiais, bem como suas aplicações em outras indústrias. Por exemplo, a hematita é usada para fabricação de pigmentos, pó para polimentos e fabricação de aço (USP, 2020). Já a barita “(...) é principal fonte de bário [usado] para a produção de substâncias químicas utilizadas na fabricação de cosméticos, papel e tecidos, como pigmento de tintas e na radiologia médica.” (USP, 2020).

A identificação de um mineral por um geólogo(a) é comumente realizada através de características do mineral a olho nu, explorando propriedades físicas desses, ou através de lâminas que são examinadas em microscópios ópticos ou eletrônicos. Algumas das propriedades que podem ser usadas na caracterização a olho nu são: a cor, dureza, transparência, hábito, clivagem, magnetismo, brilho (*luster*), traço, fratura, entre outras características (GEOLOGY PAGE, 2017),(MIKE SAMMARTANO, 2015),(MINAS JR., 2017), (SERVIÇO GEOLÓGICO DO BRASIL). Já na análise ao microscópio é possível ter informações sobre as propriedades óticas incluindo geminações, refletância do material: birefletância, reflexão interna, no caso dos minerais opacos, com definição da paragênese (quais outros minerais se encontram associados a amostras), entre outros dados (NEUMANN, 2020).

Considerando o processo acima e os avanços da computação no desenvolvimento de técnicas de aprendizado de máquina, visão computacional, mineração de dados e afins. O problema que se pretende resolver por meio do presente projeto é a classificação automática de minerais. A solução proposta consiste no desenvolvimento de um algoritmo que recebe como entrada imagens e ao final gerará como saída a classificação do respectivo mineral. O processo e o tipo de dado que serão trabalhados são ilustrados na figura abaixo:

Imagem 1 – Workflow do algoritmo de classificação



Métricas: Ex. F1, Precision, Recall, etc.

Fonte: Fotomicrografias tiradas de (NEUMANN, 2020), demais detalhes da imagem desenvolvidos pela autora.

O primeiro passo do processo é, uma vez organizada a base de dados, os dados serão divididos em dois grupos: treino e teste. As porcentagens de imagens para cada grupo na imagem são meramente ilustrativas, e poderão ser usadas outras proporções no desenvolvimento do projeto. Uma vez determinados os grupos, os dados de treino são passados para um algoritmo de classificação, por exemplo, o K-NN KNN (*K-nearest neighbors*), SVM (*Support Vector Machines*) ou o Random Forest, que então encontrarão parâmetros que melhor separa os minerais a partir das características percebidas nos dados de entrada. Uma vez feito isso, aplicamos a validação cruzada e repetimos este processo variando os hiperparâmetros que são fornecidos ao chamar a função de

classificação, até encontrarmos os melhores resultados. Quando isso acontecer testamos o modelo desenvolvido através das imagens de teste. O modelo tentará prever a *label* (classificação) do mineral gerando uma saída. Esta saída será então comparada com a *label* esperada e a partir disso será feita a avaliação do modelo por meio de métricas que analisam quão bem a inteligência artificial consegue generalizar suas previsões. As imagens de entrada consistem em fotomicrografias tiradas a partir de um microscópio ótico. No caso da figura elaborada acima as imagens de exemplo foram extraídas do livro (NEUMANN, 2020). Outras abordagens, pré-processamentos e tratamentos podem ser necessários, e serão detalhados no decorrer do texto.

2. Justificativa

Ao automatizar o processo de identificação de minerais diminui-se a subjetividade do processo de análise das amostras (ALIGHOLI, KHAJAVI, RAZMARA, 2015) e mitiga a necessidade da classificação ser feita apenas por profissionais altamente treinados (MAITRE, BOUCHARD, BÉDARD, 2019) (ZENG et. al., 2021). Além disso reduz custos, já que se gasta menos tempo para efetuar a análise, e usa materiais relativamente mais acessíveis e fáceis de manter (ALIGHOLI, KHAJAVI, RAZMARA, 2015).

Logo, a computação contribui com a solução do problema, ao prover métodos, algoritmos e técnicas como: aprendizado de máquina, processamento de imagens, entre outros. Que permitem a automatização da identificação de minerais que por sua vez torna-se mais rápida e consistente.

3. Objetivos

a. Objetivo geral:

Automatizar o processo de identificação de minerais por meio de fotomicrografias tiradas a partir de um microscópio ótico.

b. Objetivos específicos:

- Estudar as soluções e abordagens do problema já existentes
- Projetar e implementar algoritmos para classificação dos minerais
- Comparar os algoritmos entre si e com desempenhos de trabalhos anteriores.

4. Metodologia

Esta é uma pesquisa mista, a partir da qual se pretende produzir tanto um artigo quanto um protótipo. O protótipo por sua vez consiste na implementação de um algoritmo que seja capaz de classificar minerais corretamente. Como a solução proposta para este trabalho envolve técnicas de aprendizado de máquina, o desenvolvimento do trabalho levará em consideração as etapas propostas pelo método CRISP-DM.

O método CRISP-DM é uma metodologia, criada em 1996, usada para condução de trabalhos de mineração de dados e aprendizado de máquina. Ela foi criada com a intenção de ser aplicada em contextos industriais e que funcionasse independentemente de sua área de aplicação. (NCR, 1999). Seu processo é ilustrado pela figura abaixo. Por ser um processo voltado para aplicações práticas e indústrias, algumas pequenas adaptações deverão ser realizadas para que ela se adeque as necessidades do projeto em questão, conforme descrito a seguir.

Imagem 2 – Processo CRISP-DM

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives Background Business Objectives Business Success Criteria Assess Situation Inventory of Resources Requirements, Assumptions, and Constraints Risks and Contingencies Terminology Costs and Benefits Determine Data Mining Goals Data Mining Goals Data Mining Success Criteria Produce Project Plan Project Plan Initial Assessment of Tools and Techniques	Collect Initial Data Initial Data Collection Report Describe Data Data Description Report Explore Data Data Exploration Report Verify Data Quality Data Quality Report	Select Data Rationale for Inclusion/Exclusion Clean Data Data Cleaning Report Construct Data Derived Attributes Generated Records Integrate Data Merged Data Format Data Reformatted Data Dataset Dataset Description	Select Modeling Techniques Modeling Technique Modeling Assumptions Generate Test Design Test Design Build Model Parameter Settings Models Model Descriptions Assess Model Model Assessment Revised Parameter Settings	Evaluate Results Assessment of Data Mining Results w.r.t. Business Success Criteria Approved Models Review Process Review of Process Determine Next Steps List of Possible Actions Decision	Plan Deployment Deployment Plan Plan Monitoring and Maintenance Monitoring and Maintenance Plan Produce Final Report Final Report Final Presentation Review Project Experience Documentation

Fonte: (NCR, 1999)

Dentre as etapas para a execução desse projeto temos:

- 1) Revisão da literatura, que contará com pesquisas em fontes primárias como artigos e dissertações e fontes secundárias como livros e manuais, além de sites e blogs. (Corresponde a etapa de *Business Understanding* do CRISP-DM).

2) *Data Understanding*. Ao longo desta etapa a principal tarefa a ser realizada consiste na coleta de dados. Os dados a serem utilizados na pesquisa são fotomicrografias, a princípio de amostras de ferro e ouro. Elas compõem o acervo de aulas e pesquisas da professora orientadora, ou foram obtidas no Laboratório de Metalogenia no Instituto de Geociências da UFMG (IGC).

3) *Data preparation*. Nela parte os dados serão organizados, para então serem tratados e limpos. Eventuais pré-processamentos serão realizados nesta etapa.

4) *Modeling*. A etapa de modelagem se refere a modelagem do problema como um problema de classificação e, por conseguinte de aprendizado de máquina. Nela serão selecionados alguns algoritmos que se mostrarem pertinentes para a resolução do problema, por exemplo, o *Random Forest* e o K-NN. A separação dos dados em treino e teste, e outras operações relevantes para realizar a tarefa de classificação proposta.

5) *Evaluation*. Nesta etapa são calculadas métricas, por exemplo: *precision*, *recall*, F1 dentre outras para avaliar o desempenho do algoritmo e permitir comparações entre eles e comparação entre outros trabalhos similares.

A etapa de *Deployment*, não será executada dentro do escopo do presente projeto, pois no contexto da produção do presente trabalho: de um documento acadêmico, não faz sentido efetuar a entrega do sistema para um usuário específico, bem como executar planos de manutenção e entrega.

5. Revisão da Literatura

Os artigos que dão embasamento a esta pesquisa abordam o problema sobre diferentes perspectivas. Enquanto alguns como (BAYKAN, YILMAZ, 2010) e (MAITRE, BOUCHARD, BÉDARD, 2019), utilizam-se de fotomicrografias, artigos como (ZENG et. al., 2021), outros utilizam fotos de minerais macroscópicas como entrada para a classificação. Dentre os que utilizam fotomicrografias, o trabalho de (MAITRE, BOUCHARD, BÉDARD, 2019) o faz com a finalidade de identificar os minerais que compõe os grãos de areia ou silte (e eventualmente contá-los), isso é interessante uma vez que corrobora para a identificação de depósitos minerais. E por fim, os artigos (BAYKAN, YILMAZ, 2010) e (ALIGHOLI, KHAJAVI, RAZMARA, 2015) se apoiam principalmente em características como cor e demais propriedades óticas dos minerais como opacidade, pleocroísmo e birrefringência.

As pesquisas analisadas tendem a utilizar técnicas de redes neurais artificiais. Em (BAYKAN, YILMAZ, 2010) ela é utilizada, em (MAITRE, BOUCHARD, BÉDARD, 2019) são utilizadas redes convolucionais e em (ZENG et. al., 2021) aprendizado profundo. Outros algoritmos que são citados nos trabalhos são: KNN (*K-nearest neighbors*), Random Forest e CART (*classification and regression tree*, também conhecido como árvore de decisão). O artigo (BERRY, WALTERS, MCMAHON, 2008), por sua vez, não deixa claro quais métodos de aprendizado de máquina foram utilizados. Já em (ALIGHOLI, KHAJAVI, RAZMARA, 2015), ele cria uma forma de modelar que se baseia na ideia de classificadores paralelos que definem a *label* final por meio de um sistema em que a *label* indicada pela maioria dos classificadores é considerada (*Major Voting Scheme* - MVS).

Alguns dos artigos disponibilizam recursos seja de dados ou de código que podem ser úteis para o desenvolvimento do trabalho. Em (MAITRE, BOUCHARD, BÉDARD, 2019) é disponibilizado código desenvolvido em Python por meio de um *link* do Github, no entanto os dados não foram disponibilizados. Já em (ZENG et. al., 2021) foi desenvolvido um aplicativo para celular. Tal aplicativo encontra-se disponível via solicitação por *e-mail*. Já o *dataset* utilizado no trabalho em questão é público e foi adquirido através de um *web spider* no site Mindat¹. Além desses dados há uma base de dados de imagens de gemas, disponível no Kaggle², que pode ser útil no desenvolvimento do trabalho (ainda que sejam fotos da estrutura macroscópica, não micro), porque apresentam códigos desenvolvidos por terceiros que podem ajudar em etapas de pré-processamento como *data augmentation* e de outras operações e tratamentos que visam melhorar a generalização dos modelos.

6. Data Understanding

Inicialmente planejou-se fazer a classificação de minerais com utilizando as imagens da base de dados do Kaggle². No entanto com a evolução do trabalho, e a escolha por usar fotomicrografias passei a investigar outros sites os quais poderiam fornecer essas bases de imagens. Neste sentido, a professora Rosaline cedeu algumas fotos que apresentavam amostras de ouro para o desenvolvimento do trabalho e coletei algumas outras fotomicrografias do site: Alex Strekeisen³. Para garantir que estava coletando

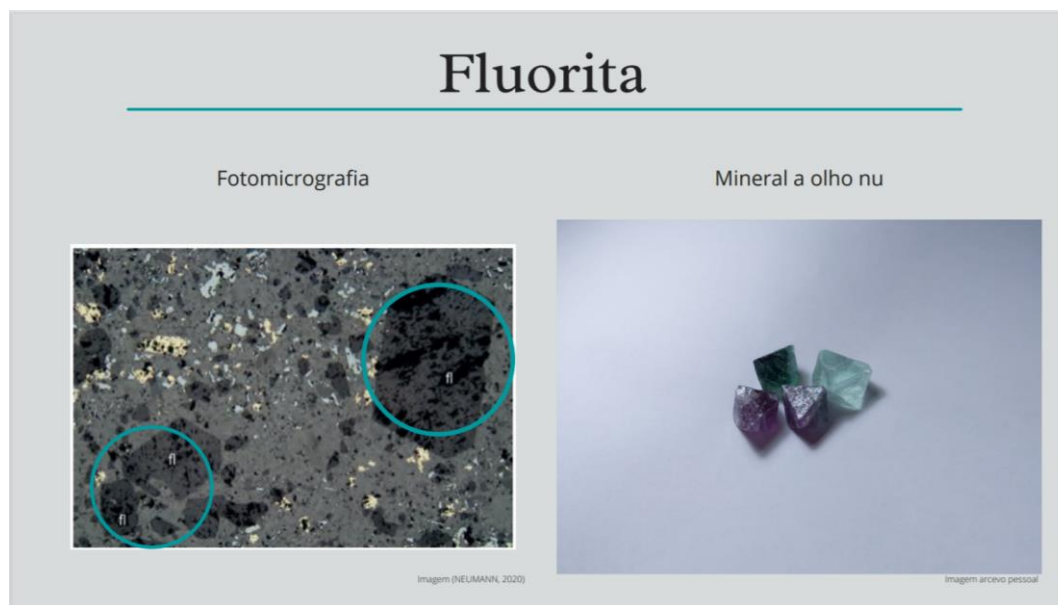
¹ <https://www.mindat.org/>

² <https://www.kaggle.com/lsind18/gemstones-images>

³ <http://www.alexstrekeisen.it/english/>

espécimes minerais, foi feita uma comparação entre as imagens obtidas e os minerais relacionados em (NEUMANN, 2020). Cada imagem foi baixada manualmente obtendo, por fim, um *dataset* com 16 classes e 415 imagens.

Imagem 3 – Diferença entre dados



Na imagem 3, acima, podem ser observadas duas imagens. A da esquerda é uma fotomicrografia, que por sua vez são imagens tiradas do microscópio de lâminas delgadas de rochas. Na foto apresentada é possível ver que, dentre outros minerais, há algumas amostras de fluorita indicada pelos círculos. Já a da direita representa um agregado monomineralico de fluorita, também. Note como as imagens contém dados e informações bem diferentes, enquanto a primeira apresenta informações do mineral e dos minerais a ele associados, a foto da direita trás outras informações como formato e cor do objeto.

Tabela 1 – Quantidade de fotos por classe


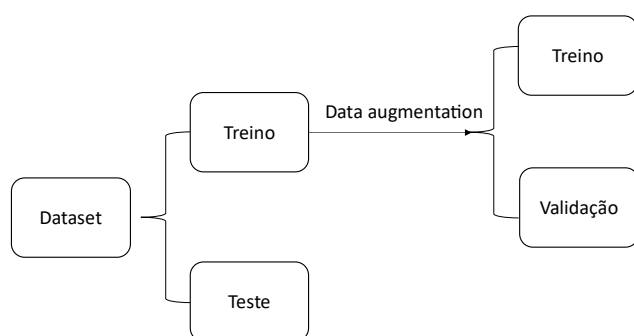
	Classes	NumFotos
2	Lazulite	46
6	Tourmaline	42
0	Olivine	38
10	Cancrinite	36
11	Topaz	36
1	Fluorite	31
3	Beryl	30
8	Garnets	30
13	Andalusite	27
4	Sodalite	20
7	Biotite	19
15	Titanite (sphene)	18
5	Calcite	13
9	Quartz	12
12	Gold	10
14	Muscovite	7

Através da Tabela 1, é possível observar quais classes compõem o *dataset*. No caso, observe que a tabela se encontra ordenada, apresentando nas primeiras células as classes que apresentam mais fotos. Neste sentido, repare que a classe que possui mais exemplares apresenta 46 imagens distintas enquanto a Muscovita apresenta apenas 7, aproximadamente 6,6% menos imagens. Tal distribuição com poucos dados em uma classe e muitas em outras é o que se chama de um *dataset* desbalanceado, e que por sua vez pode trazer problemas ao executar o algoritmo de *machine learning*.

7. Data preparation

As imagens do *dataset* continham tamanhos variados que tiveram que ser padronizados por código. Devido ao fato da base de dados está desbalanceada foram utilizados algoritmos de *data augmentation*. Foi necessário dividir os dados em três grupos a saber: treino, validação e teste. A princípio fez uma divisão errada dos grupos primeiro dividindo entre dados de treino e teste, aplicando um processo de *data augmentation* no treino e então dividindo-o em treino e validação. Mas logo percebeu-se que isso estava errado, e corrigiu-se o código de modo a primeiro separa em treino, validação e teste e depois aplicar um *data augmentation* exclusivamente no treino. Este processo é ilustrado na figura abaixo.

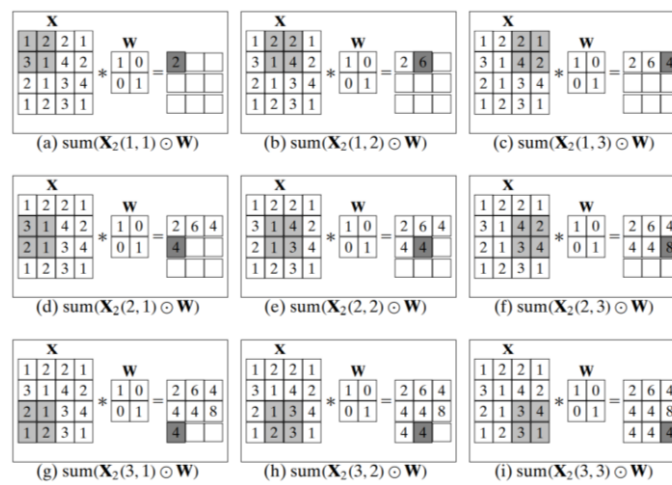
Imagem 4 – Processo



8. Modeling

Para desenvolver um classificador de minerais, optou-se por utilizar as chamadas CNN's (do inglês, *Convolutional Neural Networks*) ou Redes Neurais Convolucionais, que são o estado da arte para classificação de imagens. Elas já fazem a coleta de *features* (ou seja, atributos, características relevantes das fotografias) ao mesmo tempo que elas modelam o classificador. A imagem 5 ilustra um processo de convolução em dados bi-dimensionais. Para a implementação, utilizou-se da linguagem Python, e de bibliotecas próprias para atividades de *machine learning* como o Keras.

Imagem 5 – Etapa de convolução em 2D



Fonte: (MOHAMMED, MEIRA JR., 2020)

9. Evaluation

A métrica escolhida para avaliação do modelo foi a acurácia, ou seja, quantas imagens do total são classificadas corretamente.

10. Resultados

Para realizar a implementação do código tomou-se os códigos apresentados em: (MISHRA, 2019) e <https://www.kaggle.com/questions-and-answers/102677>⁴. O código com os modelos elaborados está disponível no GitHub: https://github.com/LarissaDG/mineral_classification. Ao longo do processo de implementação do modelo pensou-se que, pela característica de rochas serem misturas heterogêneas, e por conseguinte as fotomicrografias conterem mais de um tipo de espécie mineral, seria mais interessante usar imagens anotadas para melhorar o desempenho do classificador e deixá-lo mais focado e preciso. No entanto, devido às dificuldades

⁴ Mais especificamente o código de saravanansaminathan

adicionais que essa técnica traz e a falta de conhecimentos de geologia para identificar os minerais relevantes na amostra, optou-se por usar como rótulo para as imagens os minerais mais característicos ou relevantes das fotomicrografias. No geral, não se observou um desempenho inferior com o uso dessa abstração.

Outro detalhe do processo de implementação foi que a princípio tentei modelar as 16 classes, mas alguns comportamentos estranhos foram sendo reparados. Então optou-se por diminuir o número de classes, através do qual foi possível reparar em erros e ajustes que o programa necessitava para então ir aumentando o número de classes até as 16 classes originais. No caso foram elaborados modelos para duas, três, quatro, quinze e dezesseis classes. A acurácia do modelo é avaliada tanto na estruturação do modelo quanto nos testes, de modo a simular a aplicação prática do classificador.

Com duas classes, escolhemos a Andalusita e a Lazulita para construir o modelo. Primeiro tratamos o problema com classes balanceadas, no caso, com o mesmo número de fotos em cada classe. Neste caso configurou-se o tamanho da imagem para 200 pixels, treinou-se o modelo por 100 epochs e utilizou-se de um lote de 50 imagens. Obtendo assim uma acurácia de 1, tanto no treino, quanto na validação e teste. Depois o experimento foi refeito desta vez com dados desbalanceados e reduziu-se o tamanho da imagem para 30 pixels. De toda forma ainda conseguiu-se atingir uma acurácia de 1 tanto no treino quanto na validação e teste.

Gráfico 1 – Resultados classificação duas classes balanceadas






Gráfico 2 – Resultados classificação duas classes desbalanceadas




No caso das três classes mantivemos a Andaluzita e a Lazulite e acrescentamos os dados referentes ao Ouro. Com elas, configurou-se o tamanho da imagem para 30 pixels, e executou o treino durante 100 epochs com lotes de tamanho 50. Os dados estavam desbalanceados e neste processo alcançou-se 93% de acerto na validação conforme demonstrado pela linha laranja no gráfico mais à esquerda(abaixo). Já no teste, simulando a aplicação do modelo em um contexto real, o classificador predisse todas as classes corretamente.

Gráfico 3 – Resultados classificação três classes desbalanceadas



No caso com quatro classes, adicionou-se as imagens relativas ao mineral Calcita. Neste contexto, o tamanho da imagem foi definido para 30 pixels, treinou-se o modelo por 100 epochs, com lotes de tamanho 50 e os dados estavam desbalanceados. Ao final alcançou-se uma taxa de 94% de acerto na validação e 855 no teste. Indicando um bom desempenho prático do modelo.

Gráfico 4 – Resultados classificação quatro classes desbalanceadas

Passamos a operar com 15 classes que incorporava praticamente todas as classes originais, com exceção da Muscovita que apresentava apenas 7 imagens. No caso foram realizados 6 processos de modelagem conforme demonstrado na tabela abaixo. Note que o modelo com melhor resultado nos testes foi o 3.1 que usa imagens de 30 pixels, roda por 150 epochs com lotes de tamanho 50. Não utiliza a normalização e a taxa de aprendizado é a default. Apesar de apresentar *overfitting* o modelo ainda tem uma taxa de acerto de quase 50% o que é maior que a probabilidade do modelo acertar a classe, caso ele chutasse aleatoriamente, que seria 6,25%. Repare que praticamente todas as configurações testadas resultaram em *overfitting*, sendo a configuração 4.1 a única que não *overfittou*. No entanto, seu desempenho ficou muito ruim, só acertando 11% das imagens.

Tabela 2 – Resultados classificação quinze classes desbalanceadas

Cod_arq.	Pixels	Epochs	Batch	Normalização	Acc - modelo	Acc - Teste	Taxa de aprendizado	Overfittin
1.1	30	100	50	Não	0.5432	0.4432	Default	Sim
2.1	50	250	50	Sim	0.4000	0.1777	dr = 0.05; ds = 0.05	Sim(+)
3.1	30	150	50	Não	0.4444	0.4772	Default	Sim
4.1	50	150	50	Não	0.1110	0.1136	Default	Não
5.1	50	250	50	Sim	0.4750	0.1777	Default	Sim(+)
6.1	30	250	50	Sim	0.4750	0.2222	dr = 0.05; ds = 0.05	Sim

Já com 16 classes, todos os modelos *overfitaram*, sendo o modelo 4.2 o que apresentou melhores resultados, já que apresentou uma acurácia de 0.55 na validação e 0.53 nos testes. As configurações utilizadas foram imagens de 50 pixels, 150 epochs com lotes de tamanho 50, sem normalização e taxa de aprendizado *default*.

Tabela 3 – Resultados classificação dezesseis classes desbalanceadas

Cod_arq	Pixels	Epochs	Batch	Normalização	Acc - modelo	Acc - Teste	Taxa de aprendizado	Overfittin g
1.2	30	100	50	Não	0.4146	0.5000	Default	Sim
2.2	50	250	50	Sim	0.6098	0.1777	dr = 0.05; ds = 0.05	Sim(+)
3.2	30	150	50	Não	0.4756	0.5222	Default	Sim
4.2	50	150	50	Não	0.5488	0.5333	Default	Sim(+)
5.2	50	250	50	Sim	0.4878	0.1666	Default	Sim
6.2	30	250	50	Sim	0.5488	0.3333	dr = 0.05; ds = 0.05	Sim

Comparando os modelos com 15 e 16 classes é possível notar que adicionar a classe Muscovita não piorou os resultados do modelo. E que o modelo 4.2, mesmo *overfittado*, apresentou os resultados mais relevantes, acertando 54% das classes na validação e 53% das classes nos testes.

Tabela 4 – Análise comparativa

Cod_arq	Pixels	Epochs	Batch	Normalização	Acc - modelo	Acc - Teste	Taxa de aprendizado	Overfittin g
1.1	30	100	50	Não	0.5432	0.4432	default	Sim
2.1	50	250	50	Sim	0.4000	0.1777	r = 0.05; ds = 0.05	Sim(+)
3.1	30	150	50	Não	0.4444	0.4772	default	Sim
4.1	50	150	50	Não	0.1110	0.1136	default	Não
5.1	50	250	50	Sim	0.4750	0.1777	default	Sim(+)
6.1	30	250	50	Sim	0.4750	0.2222	r = 0.05; ds = 0.05	Sim
Cod_arq	Pixels	Epochs	Batch	Normalização	Acc - modelo	Acc - Teste	Taxa de aprendizado	Overfittin g
1.2	30	100	50	Não	0.4146	0.5000	default	Sim
2.2	50	250	50	Sim	0.6098	0.1777	r = 0.05; ds = 0.05	Sim(+)
3.2	30	150	50	Não	0.4756	0.5222	default	Sim
4.2	50	150	50	Não	0.5488	0.5333	default	Sim(+)
5.2	50	250	50	Sim	0.4878	0.1666	default	Sim
6.2	30	250	50	Sim	0.5488	0.3333	r = 0.05; ds = 0.05	Sim

11. Conclusão

Assim, conclui-se que os classificadores de 2 a 4 classes apresentaram ótimos resultados que permitem o modelo prever uma classe corretamente com taxas de acertos que variam de 86 a 100%. Já os modelos com 15 ou 16 classes praticamente todos *overfittaram*, no entanto apesar de *overfittarem* o modelo ainda apresenta taxas de acerto próximas a de 50% que são melhores que palpites aleatórios, e, portanto, são relevantes para aplicações práticas do classificador.

12. Referências Bibliográficas

ALIGHOLI, Saeed; KHAJAVI, Reza; RAZMARA, Morteza. **Automated mineral identification algorithm using optical properties of crystals**. Computers & geosciences, v. 85, p. 175-183, 2015.

BRANCO, Pércio de Moraes. **Mineral, Rocha ou Pedra?**. [S. l.], 27 out. 2016. Disponível em: <http://www.cprm.gov.br/publique/CPRM-Divulga/Canal-Escola/Mineral%2C-Rocha-ou-Pedra%3F-1047.html#:~:text=Mineral%20%C3%A9%20um%20s%C3%B3%20natural,ocorre%20em%20uma%20extens%C3%A3o%20consider%C3%A1vel>. Acesso em: 20 fev. 2022.

BRANCO, Pércio de Moraes. **Rochas**. [S. l.], 4 jul. 2015. Disponível em: <http://www.cprm.gov.br/publique/CPRM-Divulga/Canal-Escola/Rochas-1107.html#:~:text=Algumas%20rochas%20s%C3%A3o%20constitu%C3%ADdas%20por,rochas%20s%C3%A3o%20chamadas%20de%20monominer%C3%A1licas>. Acesso em: 20 fev. 2022.

BAYKAN, Nurdan Akhan; YILMAZ, Nihat. **Mineral identification using color spaces and artificial neural networks**. Computers & Geosciences, v. 36, n. 1, p. 91-97, 2010.

BERRY, R.; WALTERS, S. G.; MCMAHON, C. Automated mineral identification by optical microscopy. Australasian Institute of Mining and Metallurgy Publication Series, p. 91-94, 2008.

BROWNLEE, Jason. **How to Configure Image Data Augmentation in Keras**. [S. l.], 12 abr. 2019. Disponível em: <https://machinelearningmastery.com/how-to-configure-image-data-augmentation-when-training-deep-learning-neural-networks/>. Acesso em: 20 fev. 2022.

BROWNLEE, Jason. **How to One Hot Encode Sequence Data in Python**. [S. l.], 14 ago. 2019. Disponível em: <https://machinelearningmastery.com/how-to-one-hot-encode-sequence-data-in-python/>. Acesso em: 20 fev. 2022.

CHINNASAMY, Dinesh Kumar. **Classify Your Images using a Convolutional Neural Network**: Build a CNN from scratch to classify images. [S. l.], 16 jun. 2020. Disponível em: <https://towardsdatascience.com/classify-your-images-using-convolutional-neural-network-4b54989d93dd>. Acesso em: 20 fev. 2022.

DA MOMBIO, Alessandro. **Home**. [S. l.], 2020. Disponível em: <http://www.alexstrekeisen.it/english/>. Acesso em: 20 fev. 2022.

DESAI, Nikhil. **MultiClass Image Classification**: An overview of evaluation metrics for a multiclass machine-learning model. [S. l.], 16 abr. 2021. Disponível em: <https://medium.com/geekculture/multiclass-image-classification-dcf9585f2ff9>. Acesso em: 20 fev. 2022.

FIGUEIREDO E SILVA, R. C. **MICROSCOPIA ÓTICA EM LUZ REFLETIDA: PARTE 1**. [S.l.]: [s.n.].

FIGUEIREDO E SILVA, R. C. **MICROSCOPIA ÓTICA PARA LUZ: PARTE 2**. [S.l.]: [s.n.].

GEOLOGY PAGE. Geology Page. **How to Identify Minerals?**, 21 Abril 2017. Disponível em: <http://www.geologypage.com/2017/04/how-to-identify-minerals.html>. Acesso em: 17 Novembro 2021.

GOHAU, Gabriel. **A history of geology**. Rutgers University Press, 1990.

KAGGLE. **Questions & Answers**: How can I split the image dataset in kaggle into train and validation ?. [S. l.], 2019. Disponível em: <https://www.kaggle.com/questions-and-answers/102677>. Acesso em: 20 fev. 2022.

KERAS. **Keras homepage**. [S. l.], 2021. Disponível em: <https://keras.io/>. Acesso em: 20 fev. 2022.

MAITRE, Julien; BOUCHARD, Kévin; BÉDARD, L. Paul. **Mineral grains recognition using computer vision and machine learning**. *Computers & Geosciences*, v. 130, p. 84-93, 2019.

MARQUES, Caio. **O surgimento da Geologia**. [S. l.], 13 dez. 2018. Disponível em: <https://www.minasjr.com.br/o-surgimento-da-geologia/>. Acesso em: 16 nov. 2021.

MATPLOTLIB. **Image tutorial**. [S. l.], 2022. Disponível em: <https://matplotlib.org/stable/tutorials/introductory/images.html#sphx-glr-tutorials-introductory-images-py>. Acesso em: 20 fev. 2022.

MELO, Carlos. **Reduzindo o Overfitting com Data Augmentation**. [S. l.], 20 jun. 2019. Disponível em: <https://sigmoidal.ai/reduzindo-overfitting-com-data-augmentation/>. Acesso em: 20 fev. 2022.

MIKE SAMMARTANO. Identifying Minerals. **YouTube**, 27 Janeiro 2015. Disponível em: <https://www.youtube.com/watch?v=32NG9aeZ7_c>. Acesso em: 17 Novembro 2021.

MINAS JR. Como identificar minerais? **Minas Jr.**, 17 Julho 2017. Disponível em: <<https://www.minasjr.com.br/como-identificar-minerais/>>. Acesso em: 17 Novembro 2021.

MISHRA, PRATEEK. **MultiClass Image Classification using keras**. [S. l.], 19 set. 2019. Disponível em: <https://www.kaggle.com/questions-and-answers/102677>. Acesso em: 20 fev. 2022.

NCR, Pete Chapman et al. CRISP-DM 1.0. 1999.

NEUMANN, Udo. Guide for the microscopical identification of ore and gangue minerals. Universität Tübingen, 2020.

ODEGUA, Rising. **Image classification from scratch in keras. Beginner friendly, intermediate exciting and expert refreshing**. [S. l.], 26 out. 2018. Disponível em:

<https://towardsdatascience.com/image-detection-from-scratch-in-keras-f314872006c9>.
Acesso em: 20 fev. 2022.

PAUL, Sayak. **Learning to Resize in Computer Vision**. [S. l.], 30 abr. 2021. Disponível em: https://keras.io/examples/vision/learnable_resizer/. Acesso em: 20 fev. 2022.

RENFRO, Nathan. **Digital Photomicrography for Gemologists**. [S. l.], summer 2015. Disponível em: <https://www.gia.edu/gems-gemology/summer-2015-digital-photomicrography-gemologists>. Acesso em: 20 fev. 2022.

SCIENCE PHOTO LIBRARY. **Science Photo Library**. [S. l.], 2022. Disponível em: <https://www.sciencephoto.com/search?q=minerals+photomicrographic>. Acesso em: 20 fev. 2022.

SCIKIT LEARN. **Scikit-learn Machine Learning in Python**. [S. l.], 2022. Disponível em: <https://scikit-learn.org/stable/index.html>. Acesso em: 20 fev. 2022.

SERVIÇO GEOLÓGICO DO BRASIL. Como Identificar os Minerais. **CPRM**. Disponível em: <http://www.cprm.gov.br/publique/CPRM-Divulga/Canal-Escola/Como-Identificar-os-Minerais-1042.html>. Acesso em: 17 Novembro 2021.

SIGNIFICADOS.COM. **Significado de Geologia**. [S. l.], 11 set. 2016. Disponível em: <https://www.significados.com.br/geologia/>. Acesso em: 16 nov. 2021.

TENSORFLOW. **Tensorflow homepage**. [S. l.], 2021. Disponível em: <https://www.tensorflow.org/>. Acesso em: 20 fev. 2022.

USP. Geociências. **Hematita**. [S. l.], 23 jun. 2020. Disponível em: <https://didatico.igc.usp.br/minerais/oxidos-hidroxidos/hematita/>. Acesso em: 16 nov. 2021.

USP. Geociências. **Barita**. [S. l.], 23 jun. 2020. Disponível em: <https://didatico.igc.usp.br/minerais/sulfatos/barita/>. Acesso em: 16 nov. 2021.

ZAKI, Mohammed J.; MEIRA JR, Wagner; MEIRA, Wagner. **Data mining and analysis: fundamental concepts and algorithms**. Cambridge University Press, 2020.

ZENG, Xiang et al. **Mineral Identification Based on Deep Learning That Combines Image and Mohs Hardness**. *Minerals*, v. 11, n. 5, p. 506, 2021.